# Yapay Zeka - odev 2

Parsa Kazerooni - 19011915 @ YTU - Prof.Dr. Mehmet Fatih Amasyalı

Bu proje, YTU Yapay Zeka dersi için hazırlanmıştır. Web Scraping ile Hollanda'nin en büyük supermarket'i olan Albert Heijn üzerinden yemek urunleri ve beslenme detaylari veri olarak çekilmiştir. Sonra supervised learning algoritmalari ile bu veriler üzerinden ne kadar saglikli bir yemek oldugunu siniflandirici modeller tasarlanmistir. Saglik olcumu, Fransa'dan kaynaklanan Nutri-Score yontemidir. Sonra bu modellerin performanslari karsilastirilmistir.

---

## Kurulum

requirements.txt dosyası içerisindeki kütüphanelerin kurulumu için:

```
pip install -r requirements.txt
```

## 1. Scraping

`scraping` klasörü içerisindeki `populate_urls.py` dosyası, farkli urun kategorilerinden urunlerin url'lerini cekmektedir. Bu url'ler daha sonra `populate_products.py` dosyasinda urunlerin detaylarini cekmek icin kullanilmaktadir. Bu dosyalarin cekmis oldugu veriler `data` klasorunde bulunmaktadir.

```
python scraping/populate_urls.py
python scraping/populate_products.py
```

## 2. Data

Automation islemi, DDoS saldirisi gibi algilanmamasi icin veriler daha kucuk parcalar ve araliklar halinde cekilmistir. Bu yuzden verilerin birlestirilmesi gerekmektedir. `data` klasorunde bulunan verileri birlestirmek icin `merge_data.py` dosyasi kullanilmaktadir. Bu dosya, verileri birlestirip `data/ah.csv` dosyasina kaydetmektedir.

```
python data/merge_csvs.py
```

Yaklasik 600 farkli urunun, 20 farkli beslenme ozelligi bulunmaktadir. Bu ozelliklerin bir kismi cok az sayida bulunmakta oldugu icin, sonradan analize dahil edilmemistir. Bu yuzden, 20 ozellikten 10 tanesi secilmistir.

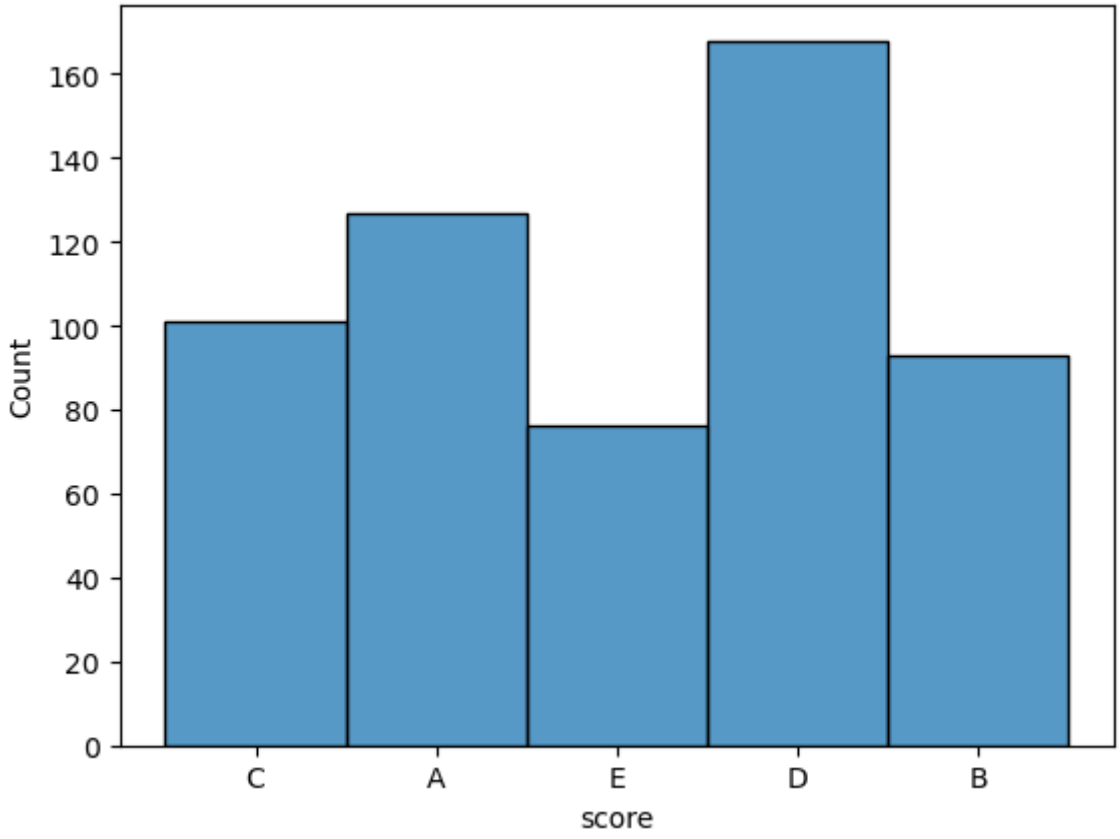


## 3. Notebook

`notebook.ipynb` dosyasi, verilerin islenmesi ve algoritmalarin egitilmesi ve karsilastirilmasini icerir.

## 4. Sonuclar

6 tane farkli siniflandirici model, Logistic Regression, Decision Tree, Random Forest, KNN, SVM ve Neural Network, kullanilmistir. Bu modellerin performanslari karsilastirilmistir. Sonuclar asagidaki gibidir:

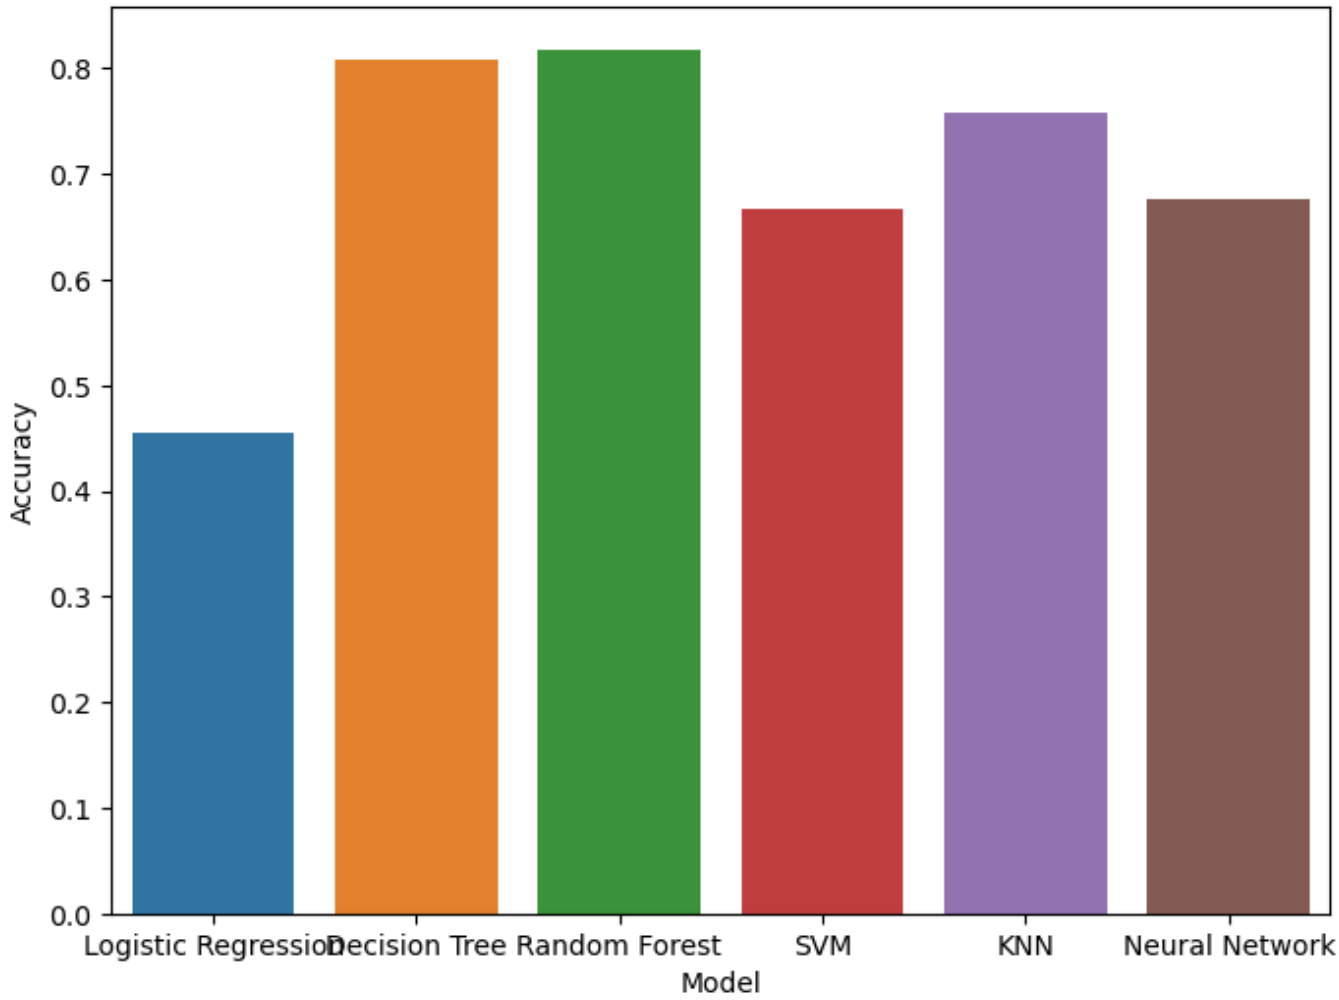


Daha iyi performans saglamak icin, Normalization ve feature selection uygulanmistir.

10-fold cross validation ile modellerin performanslari karsilastirilmistir. Her modelin score gecmisileri kaydedilmistir. ve ona gore t-testi yapilmistir. Sonuclar asagidaki gibidir:

```
Logistic Regression vs Decision Tree: t=-10.98, p=0.00
Logistic Regression vs Random Forest: t=-11.64, p=0.00
Logistic Regression vs SVM: t=-6.20, p=0.00
Logistic Regression vs KNN: t=-8.82, p=0.00
Logistic Regression vs Neural Network: t=-6.35, p=0.00
Decision Tree vs Random Forest: t=-0.29, p=0.77
Decision Tree vs SVM: t=4.24, p=0.00
Decision Tree vs KNN: t=1.53, p=0.14
Decision Tree vs Neural Network: t=3.90, p=0.00
Random Forest vs SVM: t=4.65, p=0.00
Random Forest vs KNN: t=1.85, p=0.08
Random Forest vs Neural Network: t=4.28, p=0.00
SVM vs KNN: t=-2.55, p=0.02
SVM vs Neural Network: t=-0.25, p=0.80
KNN vs Neural Network: t=2.26, p=0.04
```

## References

1. https://www.ah.nl/
2. https://en.wikipedia.org/wiki/Nutri-Score
3. https://machinelearningmastery.com/k-fold-cross-validation/